📚 IPAS AI 應用規劃師（初級）備考筆記

【單元一】AI 基礎理論、資料前處理與機器學習

本單元整合了科目一《人工智慧基礎概論》的全部評鑑大綱，並針對最新 115 年歷屆考題與考評重點進行核心提煉。

💡 核心生活譬喻：AI 的做菜哲學（從食材準備到大廚上菜）

1. **監督式學習（Supervised）**：**跟著食譜學做菜**。原料都貼好標籤（如：這是牛肉、那是豬肉），照著正確解答訓練機器。
2. **非監督式學習（Unsupervised）**：**盲聞香料分類**。沒有食譜也沒有答案，讓機器自己聞，把味道像的聚在一類（如：群集分析）。
3. **半監督式學習（Semi-supervised）**：**只有幾張標籤的食材庫**。絕大多數食材沒標籤，只有少數有標籤，利用大體分佈特性來輔助分類。
4. **強化學習（Reinforcement）**：**訓練小狗接飛盤**。沒有食譜，機器人反覆嘗試，做對了給骨頭（加分/獎勵），做錯了扣分（懲罰），逐步學會最優路線。
5. **鑑別式 AI (Discriminative) vs 生成式 AI (Generative)**：
6. **鑑別式 AI**：就像**「美食評論家」**，吃一口就知道這道菜是牛肉麵還是滷肉飯，或者打出 85 分的評分（做分類與迴歸）。
7. **生成式 AI**：就像**「創意主廚」**，憑空為您研發並做出一道世界上從未出現過的全新分子料理（創造新內容）。

---

1. 人工智慧概念與 AI 治理 (L111)

🤖 強 AI (AGI) vs 弱 AI (Narrow AI)

- **弱人工智慧 (Weak AI / Narrow AI)**：目前已實現的技術。**專注於執行單一或特定範疇的任務**（例如：下圍棋、自動駕駛、人臉辨識、異常偵測）。

- **強人工智慧 (Strong AI / AGI)**：具備與人類相當的自主認知、推理、思考與學習能力，能適應並解決各種非預設的新興任務（目前尚未完全實現）。

⚖️ 歐盟《人工智慧法案》（EU AI Act）風險分級與規範

歐盟將 AI 系統依其潛在危害程度分為四個風險等級（**必考情境判斷題**）：

1. **不可接受的風險 (Unacceptable Risk)——【禁用】**：
2. *典型情境*：政府對公民進行「社會信用評估與打分」；在公共場所進行「遠端即時生物特徵識別（如天網天眼執法）」；利用潛意識技術操縱或損害特定群體權益。
3. **高風險 (High Risk)——【嚴格受規】**：
4. *典型情境*：AI 用於「低收入補助資格審核」、「保險核保輔助」、「求職履歷自動篩選」、「學校入學資格審查」及「關鍵基礎設施管理」。
5. *規範要求*：必須進行偏誤與風險影響評估、建立**可解釋性**（如說明決策原因）與**人工申訴/複核機制**。
6. **有限風險 (Limited Risk)——【透明性揭露】**：
7. *典型情境*：使用聊天機器人（Chatbot）、生成式 AI（如產出生成式影像或文章）、Deepfake 語音或圖像。
8. *規範要求*：必須**明確主動告知使用者此內容係由 AI 自動生成**或正與 AI 系統互動，不得隱瞞。
9. **最小/低風險 (Minimal/Low Risk)——【免受規】**：
10. *典型情境*：垃圾郵件過濾器、電玩遊戲中的 AI 敵手。

🔒 AI 倫理五大核心原則

- **透明性 (Transparency)**：系統做決策的邏輯可被理解（如：醫師能理解 AI 為何將此病患判為高風險）。
- **公平性 (Fairness)**：避免演算法偏見，不得因族群、性別、種族而有顯著的核准率差異（如：避免以「性別」作為感染愛滋病的特徵，這會強化偏見）。
- **隱私性 (Privacy)**：在未經當事人告知/同意前，不得將個人敏感個資納入模型進行再訓練，傳輸過程必須加密。
- **問責性 (Accountability)**：明確開發與操作的責任歸屬，並建立救濟與人工申訴渠道。
- **安全性 (Safety & Security)**：系統防禦中间人攻擊、對抗性攻擊的穩健度。

---

2. 資料處理、前處理與去識別化 (L112)

🗄️ 三大資料型態判定

1. **結構化資料**：具備固定格式、行列關係明確的表格（如：ERP 訂單、關聯式資料庫、Excel 數值格式）。
2. **半結構化資料**：無固定行列，但具備自我描述標籤（如：XML, JSON, CSV）。
3. **非結構化資料**：無預定義模式或欄位格式，難以直接分析（如：手寫維修描述 PDF、語音錄音、產品影像檔）。

🖌️ 常見資料前處理與編碼陷阱

- **度量衡錯誤與補值**：時序資料（如溫度、電力監測）有遺漏值時，考量時間連續性，最適合使用**前後時間點的觀測值進行線性插補 (Linear Interpolation)**，而非填 0 或平均值，以防引入虛假異常。
- **Label Encoding 陷阱**：將「工程師、教師、業務」等無順序類別直接編碼為「1, 2, 3」，會使線性模型誤解為有大小關係。此時應使用 **One-Hot Encoding**。
- **數值標準化 (Standardization)**：KNN、SVM、線性迴歸對特徵尺度極為敏感，必須標準化。而**決策樹 (Decision Tree) 與隨機森林對尺度最不敏感**，不標準化也能直接訓練。
- **去識別化 (De-identification)**：為符合個資法，提供研究使用時，必須**將身分欄位替換為隨機編號且不保留任何對應關係**（若使用 MD5 雜湊但保留對照表，仍有被反推識別的風險，不符規範）。

---

3. 機器學習模型與技術理論 (L113)

⚙️ 評估指標的選擇 (Recall vs Precision)

- **召回率 (Recall / 搶救漏網之魚)**：$\frac{TP}{TP + FN}$。當**漏檢代價極高**（如：害蟲檢測、癌症篩檢、設備故障預警）時，必須優先關注 Recall，避免把「生病/異常」判為「健康/正常」。
- **精確率 (Precision / 避免狼來了)**：$\frac{TP}{TP + FP}$。當**誤判代價極高**（如：垃圾郵件過濾，怕把重要信件誤判為垃圾）時，優先關注 Precision。
- **F1 分數 (F1-Score)**：Recall 與 Precision 的調和平均數，適用於類別不平衡資料。

🛡️ k-Fold 交叉驗證與時間序列洩漏

- 在處理**時序資料（如用電量預警）**時，標準 k-Fold 交叉驗證會隨機分割資料，造成「用未來的資料去訓練模型來預測過去」的現象，這稱為 **時間序列資料洩漏 (Data Leakage)**，導致模型上線後誤差飆高。時序預測應採用滾動窗格 (Rolling window) 驗證。

🧠 深度學習與進階模型架構

- **長短期記憶網路 (LSTM)**：相較於 RNN，能有效解決長序列資料中的梯度消失問題，適合處理**長句子語音或長時間序列**。
- **Batch Normalization (批次標準化)**：在深度神經網路的隱藏層加入，能**降低不同批次輸入造成的內部特徵分佈變動 (Internal Covariate Shift)**，使梯度更新更穩定、加速收斂。
- **自編碼器 (Autoencoder)**：屬於非監督式學習，主要用於資料壓縮、降維，最常用於**異常檢測 (Anomaly Detection)**（因其無法重建異常訊號，重建誤差大即為異常）。

⚖️ 強化學習的核心問題：Explore vs Exploit

- **探索與利用的權衡 (Exploration vs. Exploitation)**：
- **Exploitation (利用)**：推薦系統總是推薦過去表現好的商品（賺取短期安全利潤）。
- **Exploration (探索)**：隨機嘗試推薦未知的新興商品，以發掘高潛力新品，但可能降低當下點閱率。

---

4. 鑑別式 AI vs 生成式 AI 與可解釋性 (L114 / L12)

👁️ 可解釋 AI 工具 (XAI)

當黑箱模型做出預測時，我們需要解釋工具來符合治理規範：

1. **顯著性圖 (Saliency Map)**：專用於電腦視覺或 NLP，能**標示出影像中（或文字段落中）對預測結果影響/貢獻度最大的區域或片段**。
2. **LIME**：一種局部解釋工具。其原理是在目標資料點附近進行擾動產生樣本，並訓練一個簡單的**線性代理模型 (Surrogate model) 來擬合黑箱模型在該局部的預測行為**。
3. **部分依賴圖 (PDP)**：呈現單一或雙特徵對預測結果的**全局整體趨勢影響**，但**無法用於判斷單一筆/單一批次瑕疵的原因**。

現代前沿模型架構 (MoE & CLIP & DINO)

- **稀疏專家混合 (Sparse MoE)**：每次運算時，路由（Router）會根據輸入，只活化模型中的部分「專家神經網路」來進行計算。這使得模型在維持龐大規模（參數多）的同時，能**大幅降低運算算力消耗、兼顧效率**。
- **CLIP**：採用自監督學習，使用 **「圖像與文字配對 (Image-Text Pairs)」** 進行對比學習。
- **DINO**：採用自監督學習，純粹使用 **「未標註的圖像資料 (Unlabeled Images)」** 進行特徵提取。
- **傳統 Transformer 的長序列限制**：自注意力機制（Self-Attention）的運算複雜度隨長度呈平方增長，且受限於**固定長度的上下文窗口 (Context Window)**，導致模型難以同時處理分散在超長全文中的不相關資訊。