

# IPAS 營運智慧分析師 學習筆記

---

## 【單元 B】資料分析與機器學習 (資料性質/敘述統計/長條圖vs直方圖/ML三門派)

---

本單元整合了考科一「基礎資料分析」以及考科二「新興數位技術」中有關**數據管理**、**統計分析**與**機器學習**的所有必考點。

---

### 核心生活譬喻：大廚如何挑選食材與烹飪（處理數據與建模）？

- **結構化資料**：就像「雞蛋盒」，一顆雞蛋一格，整整齊齊，規格完全固定（如：傳統資料庫的表格）。
  - **半結構化資料**（如 JSON, XML）：就像「大補帖便當」，雖然有格子，但格子的數量和大小可以隨時調整，極具彈性。
  - **非結構化資料**：就像一整袋「菜市場買回來的雜物」，裡面有魚、有肉、有報紙、有塑膠袋，混在一起，要花很大功夫分類才能分析（如：客服錄音、社群文字評論）。
- 

### 1. 三大資料性質與資料轉換的代價

在實務中，資料的格式可分為三類，其特性與缺點為考試重點：

| 資料類型   | 特性與優點                      | 典型範例                        | 考試常考缺點與盲點          |
|--------|----------------------------|-----------------------------|--------------------|
| 結構化資料  | 有固定欄位、固定格式、類型一致、易於整併、節省空間。 | 關係型資料庫 (RDBMS) 的表格、Excel 檔。 | 先有結構才有資料，儲存資料欠缺彈性。 |
| 半結構化資料 | 具備欄位概念，且欄位具備可拓展性，非常便於資料交換。 | XML, JSON, CSV。             | 不具備絕對的一致性。         |
| 非結構化資料 | 欄位與格式不固定，包含豐富的多媒體與文字資訊。    | 影音檔、圖檔、Email、網頁文字。          | 面對不容易分析的難題。        |

• ⚡ 核心考點

**核心考點（資料轉換的代價）：** 當我們試圖將「非結構化資料」（如文字評論）轉化為易於分析的「結構化資料」時，「重要訊息有可能在轉換過程中流失」。

2. 資料前處理、度量衡錯誤與資料稽核 (Data Audit)

在分析資料前，必須進行資料清洗與品質監控：

- **GIGO (Garbage In, Garbage Out / 垃圾進，垃圾出)：** 如果分析的輸入數據有錯，不論演算法多強，產出的決策依然是垃圾。
- **常見度量衡問題：** 合併資料時，有些資料使用「公斤」為單位，有些使用「公克」或「台斤」為單位，這屬於**度量衡錯誤**。
- **資料稽核 (Data Audit)：** 當發現資料不符原先制定的規則時，**調查其原因並研擬改善計劃**的動作，用以維護資料品質。
- **資料概述：** 確認所分析的資料與原訂的商業目標是否相關。

### 3. 統計圖表雙胞胎：長條圖 vs 直方圖

這是考試中極具殺傷力的對比觀念題：

- **長條圖 (Bar Chart)：**
  - **用途：**用於描述 **類別資料 / 屬質資料**（如：台北店、台中店、高雄店的銷售額）。
  - **特徵：**柱子與柱子之間是分開的，因為各類別是獨立不連續的。
- **直方圖 (Histogram)：**
  - **用途：**用於描述 **連續型資料 / 屬量資料**（如：來店顧客的年齡分布 20-30歲、30-40歲）。
  - **特徵：**柱子與柱子之間是緊緊相連的，因為數值是連續的。

### 4. 基礎描述統計與統計定理

#### 偏態判定

- **正偏態分佈 (右偏)：**平均數  $>$  中位數。資料大都集中在低值區，高值區有少數極端值拉高了平均數。
- **負偏態分佈 (左偏)：**平均數  $<$  中位數。資料大都集中在高值區，低值區有少數極端值拉低了平均數。

#### 箱形圖 (Box Plot) 的繪製

箱形圖能快速看出資料的統計特性，繪製時需要以下五數綜合：**最大值、最小值、中位數、第一四分位數 (Q1)、第三四分位數 (Q3)**。

#### • 出題盲點

**出題盲點：**箱形圖的繪製 **不需要「標準差」**！看到選項有標準差，直接剔除。

#### 柴比雪夫定理 (Chebyshev's Theorem)

- **公式：**至少有  $1 - 1/k^2$  的資料落在平均值加減  $k$  個標準差內（適用於**任何分佈**的資料，只要  $k > 1$ ）。
- **常考數值：**當  $k = 2$  時，至少有 **75%** ( $1 - 1/2^2 = 3/4$ ) 的資料落在平均值加減 2 個標準差範圍內。

🔔 經驗法則 (Empirical Rule)

- 適用前提：僅適用於**對稱鐘形分配（常態分配）**的資料。
- 關鍵數值：
  - 平均值加減 **1** 個標準差包含約 **68%** 的資料。
  - 平均值加減 **2** 個標準差包含約 **95%** 的資料。
  - 平均值加減 **3** 個標準差包含約 **99.7%** 的資料。

5. 機器學習三大門派對照表

機器學習（Machine Learning）是資料驅動（Data-driven）的演算法，使計算機自動從經驗中學習規律。

| 機器學習類型                   | 特點與核心觀念                                                    | 譬喻角色                  | 典型應用與演算法                                                        |
|--------------------------|------------------------------------------------------------|-----------------------|-----------------------------------------------------------------|
| 監督式學習<br>(Supervised)    | 訓練資料有標準答案（事先由人力給予 <b>標籤 Label</b> ）。在訓練過程中告訴機器答案，機器學習如何預測。 | 教徒弟做菜<br>(附上食譜標註菜系)   | 迴歸 (Regression，預測連續數值，如銷量)；<br>分類 (Classification，預測離散類別，如是否買)。 |
| 非監督式學習<br>(Unsupervised) | 訓練資料 <b>沒有人為標記</b> 的結果（無標籤）。演算法必須自主探索數據的潛在結構。              | 盲聞香料分類<br>(無說明書自行歸類)  | 群集分析 (Clustering)<br>(如顧客分群)；<br>關聯規則探勘 (如購物籃分析)。               |
| 強化學習<br>(Reinforcement)  | 機器為了達成目標，隨著環境變動而逐步調整行為，透過 <b>持續試驗與環境回饋（獎勵或懲罰）</b> 來學習最佳策略。 | 機器人煎牛排<br>(焦了扣分、好了加分) | 派單系統路徑優化、遊戲 AI、自動駕駛。                                            |

## 💡 購物籃分析 (Market Basket Analysis) & 關聯規則：

- 一種統計型分析技法，用來尋找不同商品共同被購買的關聯性（例如經典的「尿布與啤酒」故事）。屬於**非監督式學習**的範疇。
-

## 🔑 核心專有名詞英翻中對照表

| 英文專有名詞                       | 中文翻譯      | 考試核心記憶點                              |
|------------------------------|-----------|--------------------------------------|
| <b>Structured Data</b>       | 結構化資料     | 欄位固定，類型一致，儲存 <b>缺乏彈性</b> 。           |
| <b>Semi-structured Data</b>  | 半結構化資料    | 如 JSON/XML，兼具欄位概念與 <b>可拓展性</b> 。     |
| <b>Unstructured Data</b>     | 非結構化資料    | 如影音、Email。轉換為結構化時 <b>重要訊息易流失</b> 。   |
| <b>Datafication</b>          | 資料化       | 將日常商業流程與活動轉化為可分析數據的過程。               |
| <b>Data Audit</b>            | 資料稽核      | 調查不符規則資料之原因，並研擬改善計劃（維護品質）。           |
| <b>Bar Chart</b>             | 長條圖       | 柱子分開，用於 <b>類別/屬質資料</b> 。             |
| <b>Histogram</b>             | 直方圖       | 柱子相連，用於 <b>連續型/屬量資料</b> 。            |
| <b>Empirical Rule</b>        | 經驗法則      | 用於鐘形常態分配（68%-95%-99.7% 規則）。          |
| <b>Supervised Learning</b>   | 監督式學習     | 訓練資料 <b>有標籤</b> ，用於 <b>迴歸與分類</b> 。   |
| <b>Unsupervised Learning</b> | 非監督式學習    | 訓練資料 <b>無標籤</b> ，用於 <b>集群與關聯分析</b> 。 |
| <b>Clustering</b>            | 群集分析 / 集群 | 將相似特徵資料分類在一起（如：市場區隔）。                |
| <b>Deep Learning</b>         | 深度學習      | 機器學習的分支，使用複雜神經網絡層進行高層抽象。             |
| <b>GIGO</b>                  | 垃圾進，垃圾出   | 前端資料精準度錯誤，導致後端決策失效。                  |

| 英文專有名詞      | 中文翻譯 | 考試核心記憶點                  |
|-------------|------|--------------------------|
| Data-driven | 資料驅動 | 不依賴主觀經驗，純粹由海量數據引導分析與預測。  |
| Schema      | 資料模式 | 商業智慧分析前，資料庫中預先定義的資料組成關係。 |