# 運用人工智慧技術於草莓病蟲害檢測系統之研究
# A Study on the Application of Artificial Intelligence Technology in Strawberry Pest and Disease Detection Systems

**蔡鴻德[*]、何惠珍[*1]、林文燦[**]**

**Hung-Te Tsai[*], Hui-Chen Ho[*], Wen- Tsann Lin [**]**

[*]敏實科技大學人工智慧系助理教授

[*]Assistant Professor, Department of Artificial Intelligence,
Minth University of Science and Technology

[**]敏實科技大學副校長

[**]Honorary Vice President of Minth University of Science and Technology

[*1] 通訊作者 e-mail：hcho@mitust.edu.tw

## 摘要

本研究介紹了一種基於人工智慧的草莓病蟲害自動檢測系統，旨在提高草莓種植過程中的病蟲害預防效率。敏實科大師生利用自動光學檢測技術(AOI)協助農民檢測草莓葉片是否受到病蟲害侵襲。系統結合了自主移動機器人(AMR)，在無人搬運車上安裝攝像頭，進行草莓田的掃描作業，取代傳統的人工檢查。掃描結果將實時上傳至雲端，幫助農民迅速識別並移除受害草莓株。這一技術不僅節省了大量人力，還展示了人工智慧技術在智慧農業中的應用潛力，對農民提供了有效的支援。

**關鍵詞：人工智慧、AI 聯網、自動檢測系統、智慧農業 AI、草莓**

## Abstract

This study introduces an AI-based automatic detection system for strawberry pests and diseases, aimed at enhancing the efficiency of pest prevention in strawberry cultivation. Faculty and students from Minth University of Science and Technology employed Automated Optical Inspection (AOI) technology to assist farmers in detecting whether strawberry leaves are affected by pests or diseases. The system integrates Autonomous Mobile Robots (AMR), equipping unmanned vehicles with cameras to scan strawberry fields, replacing traditional manual inspection methods. The scan results are uploaded in real-time to the cloud, enabling farmers to quickly identify and remove affected plants. This technology not only significantly reduces labor requirements but also demonstrates the potential of AI in smart agriculture, providing farmers with effective support.

**Keyword: Artificial Intelligence, AIoT, Automated Detection System, Smart Agriculture AI, Strawberry**

## 壹、前言

台灣目前面臨少子化及農業就業人口下降的雙重挑戰。隨著農村人口老化和年輕人外流，農業勞動力逐年減少，平均每年減少約 2 萬 9 千人。預估到 2030 年，將有約 11 萬農民因年齡因素退出農業活動，這對台灣的農業生產和農村經濟帶來嚴峻考驗。在此背景下，智能化農業和科技創新成為解決問題的關鍵途徑。智能化農業可以透過物聯網、大數據分析、自動化設備及精準農業技術等手段，提升生產效率，減少對人力的依賴。例如，無人機可用於農田監測和施肥，而物聯網技術則可監控作物生長環境，這些措施有效提升農業生產力。

苗栗縣的大湖鄉以其優越的地理環境，成為台灣草莓產業的重要基地。該地區擁有肥沃的土壤和適宜的氣候，使草莓生長茂盛。草莓產業歷史悠久，年產值超過 18 億元，對當地經濟發展貢獻顯著。此外，大湖鄉的草莓因鮮甜的口感和良好的品質深受消費者喜愛，吸引大量遊客前來採摘，進一步促進當地的觀光產業。隨著市場需求的增加，農民們積極採用現代化農業技術，提升草莓的產量和品質，以確保傳統產業的可持續發展。

草莓以其鮮甜的口感和豐富的營養價值受到廣泛喜愛，富含維生素 C、纖維和抗氧化劑，並具備多種健康益處，如增強免疫系統、促進消化及降低心血管疾病風險。然而，草莓在生長過程中容易受到多種病蟲害威脅，如炭疽病(Anthracnose)、白粉病(Powdery mildew)及葉枯病(Leaf spot)等。傳統的病蟲害檢測方法主要依賴肉眼觀察和農民的經驗，農民透過檢查葉片、果實及根部的異常情況來判斷植物健康狀態。常見檢測方法包括觀察葉片顏色變化、果實腐爛程度及根系生長情況。此外，設置誘捕器可有效監控害蟲種類及數量，並及時採取防治措施。雖然這些傳統檢測方法有效，但隨著科技的進步，結合現代技術的檢測手段將有助於提高草莓病蟲害管理的效率和準確性。

隨著農業自動化和智能化的迅速發展，人工智慧(AI)技術在圖像識別和自動檢測領域的應用展現出巨大潛力。本研究旨在開發和應用 AI 技術，特別是自動光學檢測(Automated Optical Inspection, AOI)及自主移動機器人(Autonomous Mobile Robot, AMR)，以提升草莓病蟲害檢測的效率。透過這些技術，將能建立自動化的病蟲害監測系統，實現早期發現和及時處理，從而促進智慧農業的發展，最終為農民提供高效的病蟲害管理解決方案，降低生產成本，提升草莓的產量與品質，推動台灣農業的現代化進程。

引入 AI 技術在圖像識別和自動檢測領域的成功案例已在多個行業中顯示出其潛力。在農業領域，AI 的應用已取得顯著成效。例如，利用深度學習算法，研究人員能開發出高精度的病害檢測系統，這些系統能自動識別和分類作物病害，從而實現更快速且準確的檢測。在草莓病蟲害檢測中，AI 技術的應用不僅能提升檢測效率，還能降低人工檢測中可能存在的誤差。透過訓練深度學習模型，系統能從大量草莓葉片圖像中學習，辨識病害特徵，如葉枯病和白粉病，並即時提供診斷建議。這種自動化的檢測方式能夠及時發現病蟲害，幫助農民更有效地採取防治措施，從而減少損失並提高產量。

本研究旨在整合智慧農業管理技術、自主移動平台及 AI 視覺檢測技術，對草莓病蟲害進行監控，以提高草莓園的精準管理效率。透過這些技術的有效結合，我們能夠顯著增強對病蟲害的早期發現與防治效果，最終提供一套高效的病蟲害管理解決方案，降低生產成本，提升草莓的產量與品質，並進一步推動台灣農業的現代化進程及整體產業的可持續發展。

## 貳、文獻探討

### 一、卷積神經網絡 (Convolutional Neural Networks, CNNs)

卷積神經網絡(CNNs)是專門為處理具有格狀結構數據而設計的深度學習模型。該結構最早由 LeCun 等人(1998)提出，用於手寫數字識別，並隨後在影像識別等任務中取得了巨大的成功。其特徵在於能夠自動從圖像中提取局部特徵，透過多層的卷積操作逐層構建圖像的高層次抽象，這一特性使得 CNN 在各種影像處理任務中成為首選模型。

#### (一) CNN 的基本結構

CNN 的核心結構由多個卷積層(Convolutional Layers)和池化層(Pooling Layers)組成。卷積層的主要作用是透過一個小的卷積核(Kernel，亦稱為 Filter)在輸入圖像上進行滑動，提取局部特徵。每一個卷積核負責檢測特定類型的特徵，如邊緣、角點等。隨著網絡深度的增加，卷積層可以逐漸學習更加抽象和高層次的特徵表示。這些提取出的特徵圖會經過池化層進行壓縮，池化操作有助於減少特徵圖的空間大小，從而降低模型的計算量並提高其對位移和變形的容忍度(Scherer, Muller, & Behnke, 2010)。理論上，CNN 的特徵提取過程與人類視覺系統有相似之處，1980 年 Kunihiko Fukushima 發明了第一個神經網路架構「Neurocognitro」，並為 CNN 的發展奠定了理論基礎。

#### (二) CNN 的特徵學習與應用

CNN 之所以能夠在影像識別領域取得驚人的成功，關鍵在於其強大的特徵學習能力。特徵學習是指模型能夠自動從輸入數據中發現和提取有用的特徵，而無需手動設計特徵提取器(LeCun, Bengio, & Hinton, 2015)。相比於傳統的影像處理方法，CNN 能夠更好地處理高維度的圖像數據，並且在物體檢測、圖像分類、分割等任務中表現出色。

卷積神經網絡也能夠與其他技術結合以提高性能。例如，區域提議網絡(Region Proposal Networks, RPN)常被用於目標檢測任務中，負責生成潛在目標的區域提議。RPN 利用多尺度和多縱橫比的錨框(anchors)來掃描圖像，提出潛在包含物體的區域，這些區域隨後會進一步細化和分類(Ren et al., 2015)。

#### (三) 影像識別中的高效方法

在影像識別中，除了卷積和池化操作外，還需處理一些實際問題，如多重檢測框的重疊。非極大值抑制(Non-Maximum Suppression, NMS)是一種常見的技術，旨在去除相似或重疊度過高的預測框，保留置信度最高的檢測結果(Neubeck & Van Gool, 2006)。這項技術不僅提高了模型的準確性，還能減少重疊的預測框，從而提升整體檢測質量。

#### (四) 卷積神經網絡的優勢與挑戰

卷積神經網絡的主要優勢在於其自動化的特徵學習機制，能夠在端到端的框架下處理複雜的影像數據。然而，隨著模型規模的擴大，CNN 的計算複雜度和訓練時間也相應增加。因此，如何在實際應用中有效提升模型的運行效率，並同時保持高準確性，仍然是當前研究的重點 (He, Zhang, Ren, & Sun, 2016)。

## 二、深度學習(Deep learning)

深度學習(Deep Learning)是一種基於人工神經網絡的機器學習方法，透過多層結構的網絡來進行特徵學習與決策輸出。深度學習模型中的「深度」指的是神經網絡中的隱藏層數量，這些隱藏層使得模型能夠從大規模的數據中自動提取出高階特徵。自 2010 年代以來，深度學習技術在影像識別、語音辨識、自然語言處理等領域展現出極高的準確性與強大的學習能力，成為人工智慧技術的核心推動力之一 (LeCun, Bengio, & Hinton, 2015)。

### (一) 深度學習的基本概念

深度學習的基礎是多層神經網絡 (Multilayer Neural Networks)，其中每一層由多個神經元組成，並且相互之間存在權重連接。這些層次化的結構模仿了生物神經元系統，允許模型學習數據中的複雜模式。深度學習技術利用多層神經網絡來學習和識別圖像中的複雜模式和特徵。深度學習框架(如 TensorFlow、PyTorch 等)提供了強大的工具來構建和訓練這些網絡。深度學習模型的訓練過程主要透過反向傳播(Backpropagation) 來進行，該方法根據預測結果與實際標籤之間的誤差，調整網絡中的權重，最終達到最小化誤差的效果(Goodfellow, Bengio, & Courville, 2016)。

### (二) 深度學習的主要架構

在深度學習中，有多種神經網絡架構可用於處理不同類型的數據和任務。以下是幾種常見的深度學習架構：

1. 卷積神經網絡(CNN)：主要應用於圖像識別，透過卷積操作自動學習局部特徵，並通過池化層降低數據維度，實現高效的圖像分類和物體檢測(Krizhevsky, Sutskever, & Hinton, 2012)。

2. 遞歸神經網絡(RNN)：適合處理序列數據，如語音和文字資料。透過循環結構，RNN 能記住先前的輸入信息，進行精確預測。為了克服長序列中的梯度消失問題，改進的長短期記憶(LSTM)網絡被廣泛應用(Hochreiter & Schmidhuber, 1997)。

3. 生成對抗網絡(GAN)：由生成器和判別器組成，兩者相互對抗，生成器嘗試生成逼真的數據，而判別器則試圖分辨生成的數據是否真實。該方法特別適合於生成圖像和視頻等媒體內容(Goodfellow et al., 2014)。

4. 自編碼器(Autoencoders)：一種無監督學習方法，將數據壓縮到低維度表示，然後重建回原始數據。自編碼器在特徵學習和降噪等任務中展現良好性能(Hinton & Salakhutdinov, 2006)。

### (三) 深度學習的關鍵特性

1. 多層次結構(Multi-layer structure)：深度學習中的多層次結構主要源自於人工神經網路(Artificial Neural Networks, ANN)的發展，特別是在深度神經網路(Deep Neural Networks, DNN)中多個隱藏層的設計，使得模型能夠學習和提取更為複雜的特徵。Hinton 等人(2006)提出的深度信念網路(Deep Belief Networks, DBNs)是該領域的重要突破，證明了多層神經網路可以通過逐層訓練來捕捉數據中的高層次特徵，為深度學習的發展奠定了基礎。

2. 特徵學習(Feature learning)：深度學習通過階段性的特徵學習自動發現和提取數據中的特徵，而無需手動設計特徵提取器。這使得深度學習模型能夠處理具有很高維度的原始數據，如圖像、語音和文本(LeCun et al., 2015)。透過逐層學習數據中的層次化特徵，深度學習模型具備強大的數據表徵能力，從而在多種領域實現優異性能。

3. 端到端學習(End-to-end learning)：深度學習模型具備端到端學習的特性，從原始輸入數據到輸出結果可直接學習，無需設計多階段的人工處理流程。LeCun 等人(1998)在其圖像識別任務中應用卷積神經網絡(Convolutional Neural Networks, CNN)，開創了端到端學習的先河，這不僅簡化了模型的設計和訓練過程，還顯著提升了模型的運行效率與性能。

4. 大數據支持(Big data)：深度學習技術的發展依賴於大數據的支持，Domingos(2012)指出，深度學習模型需要大量數據來進行有效的訓練，這使得模型能夠更好地學習複雜的模式，從而提高其泛化能力。隨著大數據技術的進步，深度學習模型的性能和應用範圍得到了極大擴展。

## 三、自動光學檢測(Automated Optical Inspection, AOI)

自動光學檢測(Automated Optical Inspection, AOI)技術是一種高效的檢測方法，廣泛應用於工業領域，用於自動檢測產品的質量和缺陷。AOI 利用光學成像和數據處理技術，通過捕捉產品影像並進行分析，實現快速、準確的檢測。在農業領域，AOI 技術逐漸被探索應用於作物健康監測和病蟲害檢測。

1. AOI 技術的基本原理

AOI 主要由光源、攝影設備和影像處理單元組成。系統利用光源照射被檢測對象，並用高解析度相機捕捉反射或透射的影像。這些影像通過影像處理算法進行分析，利用邊緣檢測、顏色分析等技術，自動識別和分類缺陷。AOI 技術的核心在於其強大的圖像處理能力，能夠準確定位和識別產品中的問題(Gonzalez & Woods, 2018)。

2. AOI 在農業檢測中的應用

AOI 技術在農業領域的應用逐漸受到重視，特別是在病蟲害檢測和作物健康監控方面。利用 AOI 可以快速且準確地識別作物的生長狀況及潛在的病害問題。首先，AOI 技術能夠通過影像分析，及時識別作物上可能存在的病蟲害，幫助農民及時採取相應的措施，從而降低損失。其次，該系統可以對農田進行定期的監控，收集作物生長數據，並提供更具科學依據的管理建議。與傳統的人工檢測方法相比，AOI 具有顯著優勢。它能夠在大面積的農田中迅速篩檢作物的健康狀況，從而顯著縮短檢測時間。自動化的檢測過程不僅能有效減少人為錯誤，也提升了檢測結果的可靠性，使農業生產更加精確和高效。

3. AOI 技術在農業中的可行性與挑戰

隨著農業生產的智能化，AOI 技術在農業中的應用開始受到關注。首先，利用 AOI 可以對農作物進行實時監控，檢測病蟲害和作物生長狀況。AOI 技術能夠在大規模農田中迅速篩檢作物的健康狀況，並及時回傳相關數據，協助農民進行管理決策。此外，AOI 技術具有高效能的特點，相較於傳統人工檢測，AOI 技術可以顯著提升檢測速度與準確度，並有效降低農業生產中的人力成本。然而，AOI 技術在農業中的應用也面臨一些挑戰。首先是環境適應性的問題。農田環境中的光照變化、氣候變動等

因素可能會影響影像的質量，進而影響檢測結果的準確性。此外，農作物生長形態的多樣性以及病蟲害特徵的複雜性，使得檢測算法的設計和實施面臨挑戰。如何有效應對這些環境變數並優化檢測算法，將是 AOI 技術在農業應用中的關鍵課題。

## 四、自主移動機器人(Autonomous Mobile Robot, AMR)

自主移動機器人(Autonomous Mobile Robot, AMR)是一種具備自主導航和行動能力的機器人系統，能夠在各種環境中完成特定任務而無需人類操作。AMR 技術廣泛應用於工業生產、倉儲物流、農業等領域，並且隨著人工智慧和感測技術的發展，其應用範圍不斷擴大。

1. AMR 技術的基本原理

AMR 系統通常由感測器、導航系統和控制單元組成。感測器如激光雷達(LiDAR)、攝影機和超聲波傳感器等，能夠實時獲取周圍環境的信息。導航系統使用這些數據進行地圖構建和路徑規劃，確保機器人在複雜環境中安全行駛。控制單元負責執行運動指令，協調機器人的行為(Thrun et al., 2005)。

2. AMR 在農業中的應用

在農業領域，自主移動機器人正逐步成為一種重要的工具。它們能夠執行多種任務，如作物監控、施肥、灌溉和病蟲害檢測。具體應用包括：

(1) 作物監控：AMR 可配備影像捕捉設備，自動巡檢農田，實時收集作物生長狀況數據，幫助農民及時發現問題。

(2) 自動施肥與灌溉：通過精確的導航和控制，AMR 能夠根據作物需求，自動施肥或灌溉，提升資源利用效率。

AMR 技術在農業中的優勢包括高效性和靈活性。相較於傳統的人工勞動，AMR 可以在大面積農田中長時間工作，顯著提高生產效率。

3. AMR 技術的挑戰與未來發展

儘管 AMR 在農業中的應用潛力巨大，但仍面臨一些挑戰。環境的變化(如光照、氣候等)會影響感測器的性能，此外，農田中的不規則地形也可能增加導航的難度。為了解決這些挑戰，研究者正在探索更先進的感測技術和機器學習算法，以提升 AMR 的適應性和智能化水平。

未來，AMR 技術有望與物聯網(IoT)和人工智慧(AI)相結合，進一步增強其在農業中的應用。例如，通過實時數據分析和決策支持，AMR 能夠實現更加精準的農業管理。

## 五、產業發展歷史與現況

草莓是一種廣泛分布於溫帶地區的小漿果，營養價值高，色香味俱佳，無論是鮮食還是加工，應用都非常廣泛，是全球主要的經濟作物之一。台灣的草莓產業起步於 1934 年，當時由日本引進草莓品種進行試種。1948 年，台北區農業改良場引進了福羽品種進行試作，而蘆洲的農民也自行引進 Marshall 品種，開始進行小規模的經濟栽培。1960 年，金山農場開始進行大規模栽培，草莓種植逐漸擴展。苗栗縣大湖鄉目前是台灣最大的草莓產地。1958 年開始在大湖進行草莓試種，當時栽培面積僅

1.2 公頃。隨著農民、農會及區農業改良場的共同努力，草莓產業穩步成長。1980 年，大湖地區農會開始試辦觀光草莓園，這促使草莓栽培面積迅速擴大，如今大湖地區已成為全台草莓栽培的重鎮。

目前，草莓是台灣的重要經濟作物之一，年產值超過 18 億元，全台的草莓種植面積達 500 公頃，其中 90%的種植面積集中在苗栗縣。平均每 0.1 公頃的鮮果產值約為 15 萬至 18 萬元，而觀光採果園的產值則可高達每 0.1 公頃 30 萬元，顯示出草莓產業的高度經濟價值。根據 111 年糧食供需年報，台灣草莓總產量達 6,572 公噸，而其中大湖地區的種植面積就佔了九成，因此有「草莓王國」的美稱。然而，隨著氣候變遷的影響，尤其是夏季高溫和極端天氣的增加，台灣草莓產業面臨不少挑戰。這些挑戰包括種苗繁殖的困難、新興病害的出現，以及品種適應環境能力的問題。另外，由於國內生產成本高，尤其是人工費用佔了生產直接費用的 45%，也讓草莓產業面臨成本壓力。

為了應對這些挑戰，產業界積極推動省工化與精準化的栽培技術。以苗栗青翠草莓園為例，該園透過高架立體栽培模式，提升垂直空間利用率，同時導入滴灌技術來提高水資源的利用效率。青翠草莓園目前面積約 0.5 甲，並擁有 0.2 甲的育苗基地，採用黑網盆栽進行匍匐莖繁殖。近年來，透過這些技術的應用，高架立體栽培不僅減輕了勞動強度，還提升了 30%至 50%的工作效率，單位面積的產量也增加了 1.5 倍，幫助農場經營者擴大規模，提升收益。

草莓適合種植於 18 至 22 度的氣溫下，且需要無雨、適當灌溉的砂質土壤。土壤需深厚且富含有機質，排水及通風也需良好。草莓偏好微酸性的土壤，pH 值介於 5.7 至 6.4 之間，不耐寒冷、高溫及乾旱，尤其忌長期降雨。草莓的栽培管理期長達半年，但大湖地區氣候變化迅速，特別是在有機農法的高架草莓園中，病蟲害問題極為嚴重，如炭疽病(Anthracnose)、白粉病(Powdery mildew)及葉枯病(Leaf spot)等，這些病害一旦爆發，傳播速度極快，容易造成農民的重大損失。



圖 1 苗栗青翠草莓園

在草莓產業發展的過程中，除了面臨栽培技術的挑戰，還需要面對市場競爭、氣候變遷和生產成本的壓力。為了更好地理解台灣草莓產業的現狀與發展潛力，本研究分析台灣草莓產業的強項、弱項、機會與威脅，進而找到未來的發展方向。

表 1 台灣草莓產業 SWOT 分析表

| 優勢(S) | 劣勢(W) |
|---|---|
| 1. 苗栗大湖草莓產量全台第一，觀光草莓園享負盛名<br>2. 農改場與草莓農合作，已有完整產業鏈與技術積累 | 1. 草莓園分散且獨立，不容易達到落實科技農業的經濟規模<br>2. 因分散且獨立，管理與維護單位成本相對較高 |
| 機會(O) | 威脅(T) |
| 2. AI 視覺檢測與精準灌溉技術可提升草莓栽培的效率，減少病蟲害的損失<br>3. 物聯網技術成熟，應用成本降低，有助於科技農業發展 | 1. 日本、美國高價跟品質進口草莓，尤其白草莓稀有且受歡迎<br>2. 氣候變遷帶來的極端天氣以及病蟲害可能造成大規模損失，增加農民經營風險<br>3. 農村人口老化與少子化影響，從事農業的人力大量減少，急需自動化 |

## 參、研究方法與步驟

### 一、研究架構

本研究旨在開發一套高效的草莓病蟲害識別系統，透過自主移動平台(AMR)進行自動化檢測，提升病蟲害識別的準確性和穩定性。為達成此目標，本研究將分為三個主要部分，並依據其重要性和權重進行劃分。本研究共分為三個分項，具體劃分及權重如下：

(一) 建立 AMR 自主移動平台【權重 30%】：

1.硬體架設【5%】；2.感知訓練【10%】; 3.導航訓練【10%】; 4.集成測試【5%】。

(二) 建立病害視覺演算法【權重 40%】:

1.數據收集與預處理【15%】；2.演算法模型訓練【20%】; 3.集成測試【5%】。

(三) 田口方法驗證【權重 30%】:

1.實驗設計【10%】；2.優化草莓病蟲害識別系統的準確性與穩定性【20%】。

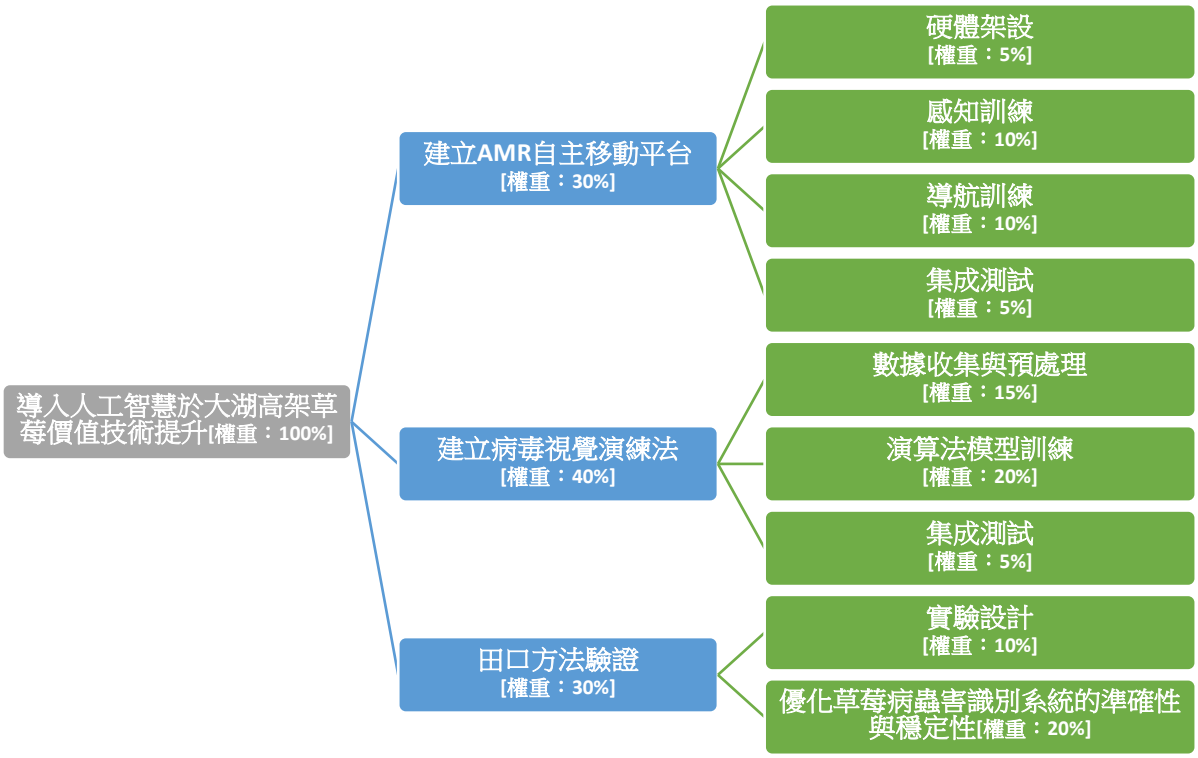



圖 2 研究架構與實施方式

## 二、實施方法

### (一) 建立 AMR 自主移動平台

隨著自動化技術的飛速發展，自主移動機器人(Autonomous Mobile Robots，AMR)在農業領域的應用日益受到重視。AMR 具備高效且自主的移動能力，能夠在複雜的農業環境中進行精確的作業，從而大幅提升生產效率並減少人力成本。在高架草莓園的環境中，AMR 可應用於育苗區與種植區的監控、病害檢測與巡檢等任務，為智慧農業提供重要的技術支持。本研究旨在建立一個適應草莓園環境的 AMR 自主移動平台，從環境評估、硬體設置、軟體配置到感知與導航模組的訓練與集成，最終實現機器人在草莓園中的自動巡檢、病害檢測與路徑規劃。本平台的設計不僅滿足當前農業作業需求，還具備持續學習與優化能力，隨著技術進步不斷提升性能和穩定性，為農業自動化提供源源不斷的創新動力。

為了達成研究目標，本研究規劃了一套完整的流程，涵蓋從環境評估到系統測試的各個階段。以下為具體的執行步驟說明：

1. 環境評估

高架草莓園分為育苗區與種植區，園區環境複雜，地形、土質及日照情況等因素將影響機器人的移動效果。在此階段，對草莓園進行詳細的環境評估至關重要，以便確定適合機器人操作的區域及路徑。

2. 硬體設置

(1) 感測器安裝：安裝相機、激光雷達(Lidar)、慣性測量單元(IMU)等感測器，以便 AMR 能夠準確地獲取環境數據。

(2) 電機與控制器：配置機器人的電機與控制器，確保其具備良好的移動性能，能夠精確控制速度與方向。

3. 軟體配置

(1) 安裝 ROS2：ROS2(Robot Operating System 2)是一個為機器人開發設計的開源框架，能夠提供機器人的感知、導航與控制功能。將 ROS2 安裝在 AMR 的主控板上是整個系統運行的核心部分。

(2) 配置驅動程序：確保所有硬體設備的驅動程序正確安裝與配置，使 AMR 能夠與感測器、電機和其他硬體設備協同工作。

4. 感知模組訓練

(1) 數據收集：使用相機與激光雷達收集草莓園的環境數據，這些數據包括圖像、深度資訊等。

(2) 數據標註：對收集到的數據進行詳細標註，這包括標記病害草莓的位置、種類及其嚴重程度等，從而生成一個專門用於訓練的數據集。

(3) 訓練目標檢測模型：利用已標註的數據集來訓練目標檢測模型，像是 YOLO 或 Faster R-CNN。這些模型能夠有效識別並定位草莓病害區域。在訓練過程中，可以選擇 TensorFlow 或 PyTorch 這些流行的深度學習框架來實現，並調整模型的超參數(如學習率、批量大小)，以優化模型性能。

(4) 部署模型：將訓練好的模型部署到機器人的主控板，並進行測試以確保其性能。

5. 導航模組訓練

(1) 地圖構建：基於激光雷達數據構建草莓園的地圖，通常使用 SLAM(同時定位與地圖構建)算法來完成。

(2) 路徑規劃：在生成的地圖上設計機器人的運動路徑，確保機器人能夠高效地巡檢草莓園。

(3) 避障算法：實現動態避障功能，通過激光雷達與攝像機的數據結合，確保 AMR 能夠動態避開障礙物。

6. 整體系統集成與測試

(1) 集成感知與導航模組：將感知模組和導航模組集成到 ROS2 架構中，確保兩者能夠協同工作。

(2) 仿真測試：使用 Gazebo 等仿真環境進行初步測試，檢驗機器人的感知與導航功能。

(3) 實地測試：在實際草莓園環境中測試機器人，調整參數以提高性能和穩定性。

(4) 反饋迭代：根據實地測試結果進行迭代改進，優化感知、導航算法和硬體設置。

7. 持續學習與改進

(1) 在線學習：AMR 通過持續運行過程中收集的數據進行模型的在線學習與優化，不斷提升其性能。

(2) 定期更新：根據新技術與研究進展，定期對機器人的軟硬體進行更新，保持其先進性與適應性。

**(二) 建立病害視覺演算法**

針對智慧草莓園的病蟲害自動化檢測與管理，建立高效的病蟲害視覺演算法至關重要。透過深度學習技術與圖像處理，能大幅提升病蟲害的自動辨識與實時管理效率。以下是具體的執行步驟：

1. 數據收集

(1) 圖像收集：拍攝大量含有不同病蟲害的植物圖像。確保涵蓋各種不同光照、角度和背景條件下的圖像，以提高模型的泛化能力。

(2) 數據來源：可以從田間實地拍攝、公開數據集(如 PlantVillage)或農業研究機構等獲取圖像數據。

2. 數據標註

(1) 手動標註：使用標註工具對圖像進行標註，標示出病蟲害的位置和類型。

(2) 標註格式：常用的標註格式有 Pascal VOC、COCO 等，選擇適合模型訓練的格式進行保存。

3. 數據處理

(1) 數據擴增：使用數據擴增技術(如旋轉、翻轉、縮放、色彩調整等)來增加訓練數據量，減少過擬合。

(2) 數據分割：將數據集分成訓練集(80%)、驗證集(10%)和測試集(10%)，以提升模型的可靠性和泛化能力。

4. 模型選擇與訓練

(1) 選擇模型：選擇如 YOLO、Faster R-CNN 或 RetinaNet 等適合目標檢測和圖像分類的深度學習模型。

(2) 模型構建：基於深度學習框架設計模型架構，並調整學習率、批次大小等超參數。

(3) 模型訓練：使用訓練數據集進行模型訓練，設置合適的超參數進行訓練。

5. 模型評估與調整

(1) 性能評估：使用驗證集和測試集進行模型的準確度和效率評估，評估指標包括準確率、召回

率、F1 分數和 mAP 等。

(2) 模型調整：根據評估結果優化模型架構及超參數，重複多次訓練迭代以達到最佳性能。

6. 模型部署

(1) 優化模型：使用工具優化模型，減少模型大小和推理時間，以便在嵌入式設備或移動設備上運行。

(2) 部署環境：將優化後的模型部署到實際應用場景中，如機器人的主控板或邊緣計算設備上。

(3) 實時推理：在實際應用中進行即時病蟲害檢測，並與相關的自動化管理系統結合，實現病蟲害的即時反應。

7. 持續監控與更新

(1) 監控性能：持續監控模型在實際應用中的表現，收集新的數據進行分析。

(2) 模型更新：根據監控結果和新收集的數據進行模型更新，保持模型的準確性和可靠性。

### (三) 以田口方法驗證優化草莓病蟲害識別系統的準確性與穩定性

現代農業中，草莓病蟲害的準確識別對於提高農作物的產量和質量至關重要。傳統的病蟲害識別方法通常依賴於人工觀察，不僅效率低，且容易出現誤判。隨著自動化與智能化技術的發展，利用自主移動機器人(AMR)搭載高清鏡頭，結合卷積神經網絡(CNN)和深度學習技術，可以實現對病蟲害的自動化識別。然而，這些系統的準確性可能會受到圖像分辨率、光照條件、環境背景以及模型參數等多種因素的影響。因此，本實驗旨在通過田口實驗方法系統地評估並優化這些因素，以提升草莓病蟲害識別系統的準確性和穩定性。為達成此目標，執行步驟如下：

1. 識別影響因素：使用田口方法探討自動光學檢測機台的最適參數，以光源、鏡頭解析度等重要因子，進行實驗，找出草莓檢測中降低漏檢及誤判的最適參數。接著使用 ANOVA 變異數分析，檢驗品質特性是否出現誤判。

2. 選擇實驗因素和水平：為每個影響因素選擇合適的水平，以便設計實驗。每個因素設置三個不同的水平，便於全面分析。

3. 設計實驗方案：利用田口實驗方法中的正交表設計實驗方案，確保在有限的實驗數量內系統地評估各種因素組合對識別準確性的影響(表 2)。田口實驗設計直交表是一個矩陣，其中行代表控制因子，列代表不同的實驗條件。在表中填入的數值代表每個控制因子在該條件下的水準數。

表 2 草莓病蟲害識別系統實驗因素及其水平設置

| 控制因子 | 水平 1 | 水平 2 | 水平 3 |
|---|---|---|---|
| 解析度 | 720 | 1080 | 4K |
| 光源設置 | 晴天 | 陰天 | 雨天 |
| 拍攝角度 | 0 度 | 45 度 | 90 度 |

| 控制因子 | 水平 1 | 水平 2 | 水平 3 |
|---|---|---|---|
| 拍攝距離 | 10 公分 | 20 公分 | 30 公分 |
| 圖像預處理技術 | 去噪 | 增強 | 標準化 |
| 目標檢測模型 | YOLO | Faster R-CNN | SSD |
| 訓練超參數 | 學習率 0.01 | 學習率 0.001 | 學習率 0.0001 |

4. 執行實驗和數據收集：按照設計的實驗方案進行測試，記錄每個組合條件下的識別準確性數據
   (1) 依直交表的組合模型進行實驗。
   (2) 每組實驗以屏蔽框(Frame)進行測試。
   (3) 每組實驗以屏蔽罩(Cover)進行測試。
   (4) 實驗數據收集完成後，進行統計與分析。
   (5) 確認實驗結果是否達成效益。
5. 分析實驗結果：計算每個實驗條件的信噪比(S/N 比)，評估各因素水平對系統準確性的影響，並找出最佳參數組合。

關於田口方法，本研究應用其兩項主要功能。首先，通過應用直交表來均衡設計目標函數的穩定性與變數權重。其次，通過田口實驗獲得的資料，找出影響製程的關鍵因子。該方法不僅可以減少試驗次數，還有助於進行概略或範圍巨大的工作分析，其特性包括實驗工作方便和實驗時間迅速等，最終可整理出各參數對整體目標函數最佳化的影響特性。

田口方法的模式配置使用直交表進行，選取穩健參數的考量依據為 S/N 比(信號/雜音比)，以較少的試驗獲取可靠數據。值得注意的是，田口方法對於連續型因子僅能找出區域最佳解，而無法得知因子之間的交互作用。因此，另採用反應曲面法的實驗設計方式(如圖 3)，結合數學與統計等工具，以顯著提升尋找因子間交互作用及建立數學模型的能力。為建構草莓病蟲害辨識的最佳化參數，本研究以田口實驗所求得之因子作為反應曲面法的考量因子，再設計反應曲面實驗以找出最佳參數組合，並將結果列出以比較差異。

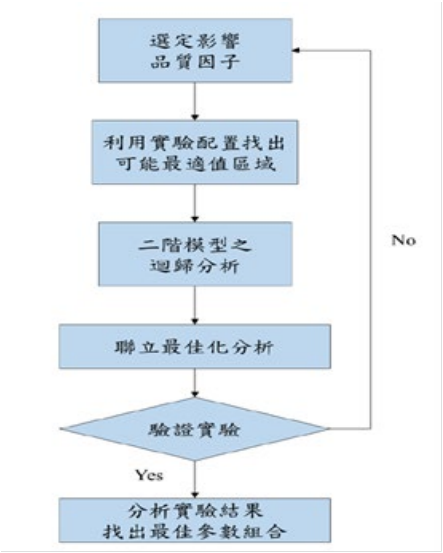



圖 3 反應曲面實驗流程

在田口實驗中定義 S/N 比後，計算其值，並獲得因子對 S/N 比的反應圖與反應表。反應表中將各水準之因子效應(Effect)測量最大值減去最小值，以訂定最佳參數組合，並將此組合代入反應曲面實驗中進行檢驗。

6. 驗證和確認最佳參數組合：六標準差解決問題的方法以流程改善為主，運用構思方法對現有流程進行改進。其包含五個階段步驟：
   (1) 構思解問題之方案：提出多種可能的解決方案。
   (2) 篩選解決方案之數量：評估並縮小解決方案的選擇範圍。
   (3) 選出可行之解決方案：從篩選的方案中選出最佳的可行方案。
   (4) 執行作業流程之改進：根據選定的解決方案實施改進措施。
   (5) 再次測量改善結果：測量結果以確認是否達到預期的成效。

最後，再利用進行實驗得出之最適解執行反覆檢驗，檢驗實驗數據是否滿足常態分佈，同時比較實驗前後製程能力指標 $C_{pk}$ 是否有所提升。本研究所使用的方法與工具構建的實驗步驟能有效求得製程的最佳參數組合，並提升辨識準確度。

表 3 田口實驗 L9 正交表設計實驗

| 實驗編號 | 圖像分辨率(A) | 光照條件(B) | 環境背景(C) | CNN 模型參數(D) |
|---|---|---|---|---|
| 1 | 高(A1) | 自然光(B1) | 簡單背景(C1) | 模型 1(D1) |
| 2 | 高(A1) | 人工光(B2) | 複雜背景(C2) | 模型 2(D2) |
| 3 | 高(A1) | 混合光(B3) | 簡單背景(C1) | 模型 3(D3) |
| 4 | 中(A2) | 自然光(B1) | 複雜背景(C2) | 模型 3(D3) |
| 5 | 中(A2) | 人工光(B2) | 簡單背景(C1) | 模型 1(D1) |
| 6 | 中(A2) | 混合光(B3) | 複雜背景(C2) | 模型 2(D2) |
| 7 | 低(A3) | 自然光(B1) | 簡單背景(C1) | 模型 2(D2) |
| 8 | 低(A3) | 人工光(B2) | 複雜背景(C2) | 模型 3(D3) |
| 9 | 低(A3) | 混合光(B3) | 簡單背景(C1) | 模型 1(D1) |

## 三、創新性

隨著全球對生產效率的需求增加，智慧農業的發展已成為當前農業技術創新的重要趨勢。本研究將重點介紹 AI 技術在智慧草莓園計劃中的應用，特別是自主移動機器人(AMR)在環境監測和病害識別中的關鍵角色。表 4 展示 AI 技術導入前後的變化。

表4 AI導入前後比較表

| 目標項目 | AI 導入前 | AI 導入後 |
|---|---|---|
| 1. 技術狀況<br>2. 產業狀況 | 1. 由人工靠經驗進行環境、土壤、養分及病蟲害等田間巡檢及管理。<br>2. 少子化導致農業人才流失，經驗傳承斷層，產量達到瓶頸 | 1. 自動巡檢機器設備以 AI 視覺技術及大數據演算法偵測病蟲害病徵，更精準快速發現與治療<br>2. 精準治療與預防降低投藥成本與藥物殘留，提高產量 |

在智慧草莓園計劃中，使用 AMR 實現病害視覺判別和自主導航。透過相機和 Lidar 等感知模組，AMR 能夠獲取草莓園的環境數據，並使用 ROS2 協調處理和運動控制，使機器人能夠精確地在園區內自主移動和進行作業。ROS2 是一個開源的機器人操作系統，提供框架和工具來幫助開發機器人應用。它支援分布式計算，使得多個處理單元可以協同工作。

(一) 採用 AMR ROS2 自主移動平台自動巡檢

1. 導航與定位：使用 SLAM(Simultaneous Localization and Mapping)技術，實時生成地圖並定位機器人在地圖中的位置。
2. 路徑規劃：計算從當前位置到目標位置的最佳路徑，確保高效作業。
3. 感知與感測：通過激光雷達(LiDAR)、相機和 IMU(慣性測量單元)進行數據處理，以提高環境感知能力。
4. 運動控制：實現機器人的運動控制，包括速度和轉向的調節，確保機器人能夠平穩運行。
5. 通信：ROS 2 的通信機制基於話題(Topic)、服務(Service)和行動(Action)模型，適用於數據流、請求/應答和長時間任務等多種場景。



圖 4 自主移動機器人

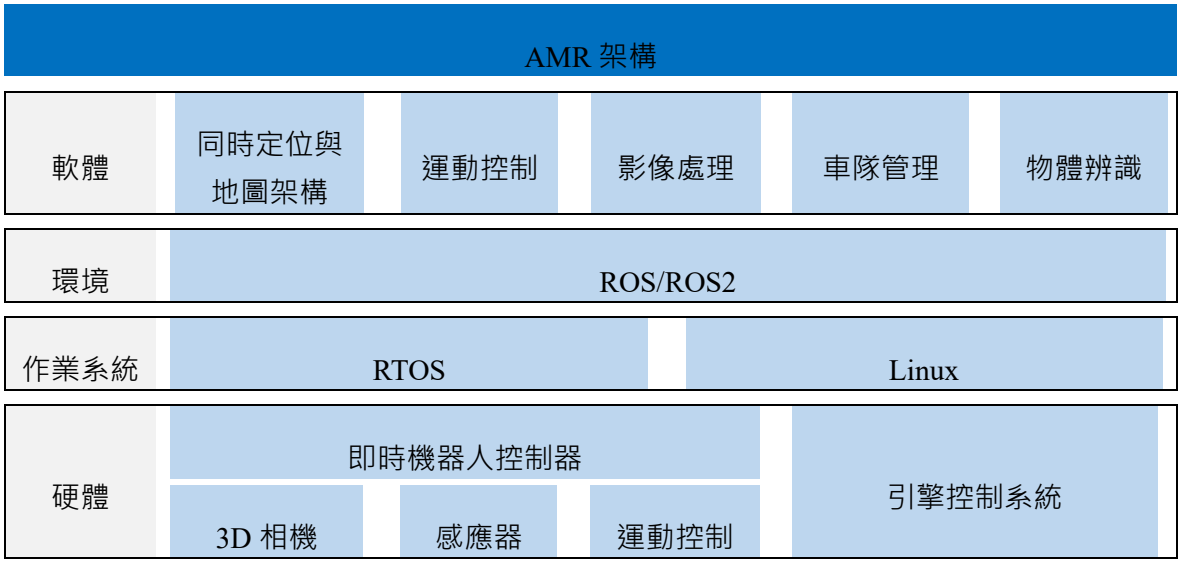



圖 5 AMR 架構

自主移動機器人(Autonomous Mobile Robots，AMR)的硬體層架構包括多種元件，每個元件在機器人的感知、運動控制和計算能力方面扮演著關鍵角色。

(1) 感知層

- 相機和視覺感應器：用於環境感知、物體識別和導航，包括 RGB 相機、深度相機(如 Intel RealSense)、立體相機等。
- 光達(Lidar)：提供高精度的環境距離測量，生成 2D 或 3D 地圖。
- 超聲波感應器：用於近距離障礙物檢測，輔助避障。
- IMU(慣性測量單元)：測量機器人的加速度和角速度，提供姿態估計。

(2) 運動控制層

- 電機和驅動器：控制機器人的移動，包括輪式、履帶式或腿式驅動。
- 電機控制器：調節電機的轉速和方向，通常使用 PID 控制算法。

(3) 計算層

- 主控板：處理器或微控制器，運行機器人的核心軟體(如 ROS2)。
- 嵌入式系統：管理低層硬體操作，如 Arduino、STM32 等。
- 通信模組：支持 Wi-Fi、Bluetooth、ZigBee 等通信技術，用於與其他設備或機器人通信。

(4) 電源管理層

- 電池組：提供機器人運行所需的電力，通常是鋰電池。
- 電源管理系統：管理電池充電和放電，保護電池壽命和機器人安全運行。

(二) 採用演算法識別病害

使用卷積神經網路(CNN)進行草莓植株病徵視覺檢測的步驟可分為多個階段，每個階段在處理與分析影像時都發揮關鍵作用。從輸入影像到輸出檢測結果，整個流程結合了特徵提取、候選區域生成和分類等技術，從而有效檢測草莓葉片上的病徵，如圖 6。

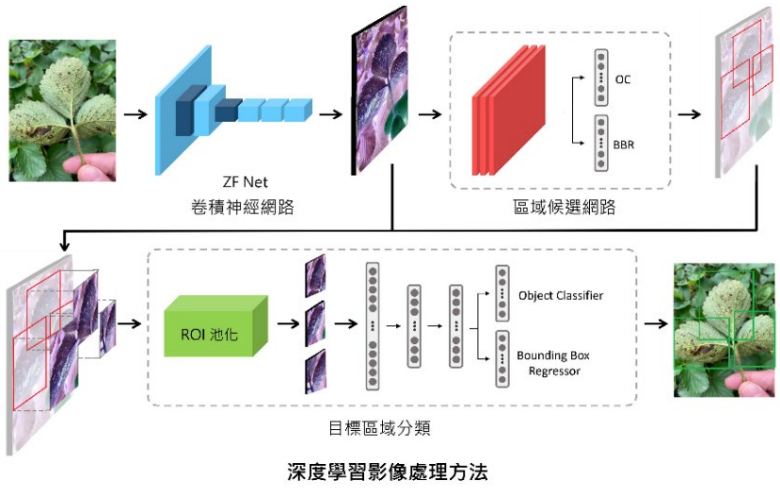



圖 6 草莓植株病害識別圖

**Step 1: 輸入影像**

- 使用相機或其他設備拍攝草莓植株的影像。
- 影像應包含健康部分與可能受病害影響的部分，並通常為高分辨率，以捕捉細節特徵(如病斑、葉片變色)。

**Step 2: 特徵提取[使用 ZF Net CNN]**

- 將影像輸入 ZF Net 卷積神經網路。
- CNN 自動提取影像中的特徵，如邊緣、紋理、顏色變化等，逐步學習並提取高階特徵，為後續檢測病徵打下基礎。

**Step 3: 區域候選生成(RPN)**

- 影像經過特徵提取後，傳送至區域候選網路(RPN)。
- RPN 生成多個候選框，這些框代表影像中可能包含病徵的區域。RPN 的作用是篩選影像中的潛在感興趣區域，縮小分類器後續處理的範圍，減少計算量。
- RPN 會產生大量候選框，其中一些可能包含病徵，而另一些可能是正常的植物部分。

**Step 4: ROI 池化**

- 將 RPN 生成的候選框進行 ROI 池化，統一為相同大小。
- 確保候選區域的特徵以一致格式輸入分類網路，便於後續精準分類。

**Step 5: 目標區域分類與邊界框回歸**

- 進行候選區域分類，使用分類器(Object Classifier)判斷候選框是否包含病徵。
- 同時使用邊界框回歸器(Bounding Box Regressor)來精確定位病徵區域的邊界，將病徵的位置標示在影像中。

**Step 6:輸出結果**

- 在影像上標示出檢測到的病徵區域。
- 幫助農民或農業專家快速識別受病害影響的草莓植株部分，制定防治策略。

整個過程是基於深度學習技術的，能夠自動學習影像中的特徵，並準確檢測出病徵。這種方法相較於傳統的人工檢測具有更高的準確性與效率，能夠大規模應用於農業中，幫助農民提高作物健康管理的水平。

## 肆、結果與討論

### 一、實驗結果

這次草莓病害影像辨識模型的初步訓練，主要是為了建立一個能準確識別多種草莓病害的深度學習模型。我們使用了 2958 張影像資料，包括七種病徵的影像及一組健康樣本，這些資料被分成訓練集(1934 張)、驗證集(308 張)和測試集(716 張)。主要目的是讓模型透過這些資料進行學習，實現草莓病害的自動化識別。

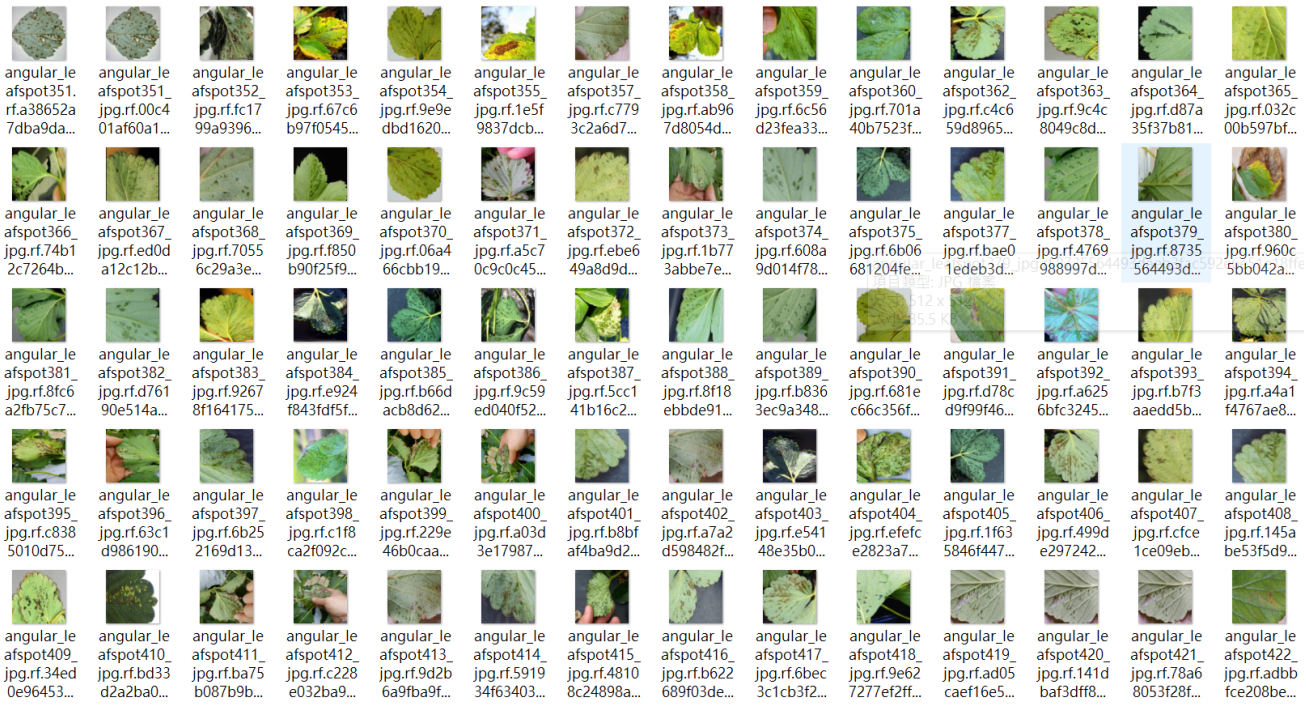


圖 7 訓練與測試集影像資料

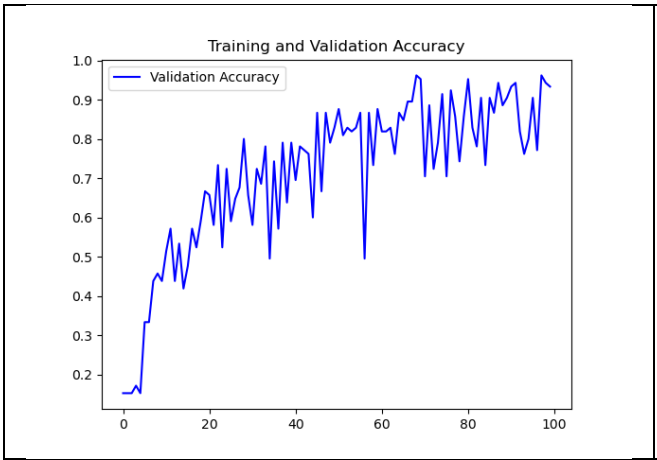
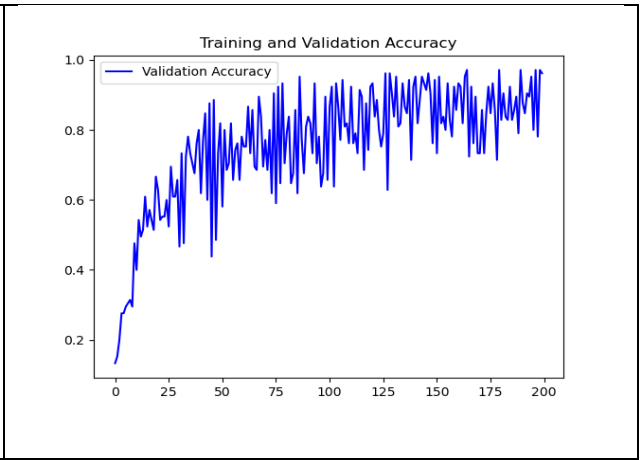
在第一階段的模型設計中，採用較小的數據集進行訓練、驗證和測試(105 張照片)，這樣做是為了快速了解模型在小樣本下的表現，並快速調整模型的結構和參數。在初步訓練的過程中，模型經歷了 100 次和 200 次的訓練週期，目的是讓模型熟悉數據並進行基本的學習。雖然這樣的訓練次數讓模型有了一些初步的識別能力，但結果顯示模型的準確度還不理想，並且在驗證集上的表現波動很大，顯示出學習過程的不穩定。

在第二階段，我們將訓練次數提高到 500 次和 700 次。隨著訓練次數的增加，模型的識別能力逐漸提升，並且在驗證集上的表現變得更穩定。然而，震盪問題依然存在，可能是由於學習率過高或訓練數據在某些維度上的變化過大所導致的。

為了進一步提高模型的穩定性，在第三階段的訓練中，我們加入了動態學習率調整的機制。這個策略的目的是讓模型在訓練的不同階段根據學習狀態自動調整學習速率，這樣可以在初期加快模型的收斂速度，而在後期則減慢學習步伐，避免模型陷入局部最優解或過度調整數據的細微差異。動態學習率的引入顯著減少了模型的訓練震盪，使得表現更為穩定。

接著，我們進一步調整了目標圖像的大小，這樣做是為了讓模型在處理影像時能更專注於重要特徵，過濾掉不必要的雜訊。這一調整也對模型的表現起了正面的影響，進一步提高了識別的準確度。經過這一系列的優化措施後，模型的穩定性和準確度都有顯著提升，特別是在測試集上的表現更加一致。

總結來說，這次草莓病害影像辨識模型的初步訓練顯示，隨著訓練次數的增加以及動態調整學習率等技術的應用，模型逐漸學會了如何更有效地識別草莓病害，穩定性也有明顯改善。雖然這只是初步階段的訓練，但已為後續更大規模的訓練和優化打下基礎。在未來的工作中，我們將繼續增加訓練數據量、調整模型結構，並引入更多的優化算法，進一步提升模型性能，最終實現準確且高效的草莓病害自動辨識系統。

<table>
<tr>
<td> 
</td>
<td> 
</td>
</tr>
<tr>
<td>100 次</td>
<td>200 次</td>
</tr>
</table>

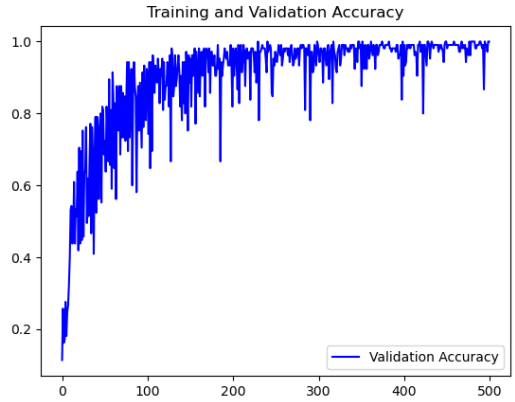
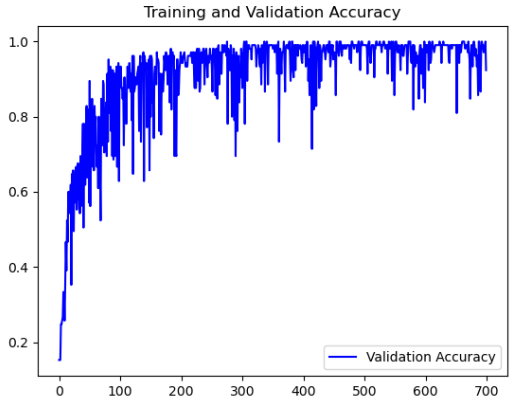
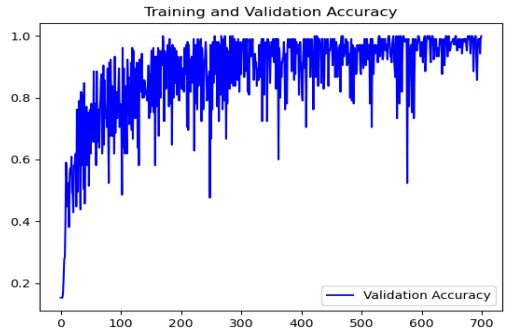
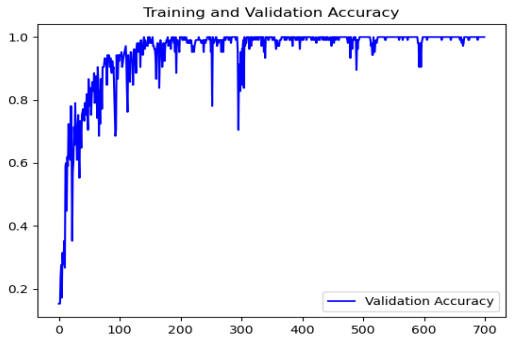
<table>
<tr><td> 
</td><td> 
</td></tr>
<tr><td>500 次</td><td>700 次</td></tr>
<tr><td> 
</td><td> 
</td></tr>
<tr><td>700 次 ＋ 動態調整學習率<br>(降低震盪幅度)</td><td>700 次+ 動態調整學習率+調整目標圖大小<br>(降低震盪幅度)</td></tr>
</table>

圖 8 動態模型訓練圖

## 二、系統效益

透過應用 AOI(自動光學檢測)和 AMR(自主移動機器人)技術，草莓病害的檢測效率得到了顯著提升。相較於傳統的人工檢測，該自動化系統能夠在更短時間內檢測更多的草莓植株，顯著減少人力成本，並提高檢測準確度。特別是在動態學習率調整和目標圖像大小調整後，系統的穩定性和精度進一步提高，對於病害的早期發現和處理尤為重要，如圖 8。

本系統顯著縮短了檢測時間，使農民能夠更及時地採取措施；另一方面，透過自動化技術的應用，大幅度降低了人力需求，節省了成本，從而促進了農業產業的發展與智慧農業的推進。整體而言，這些效益使得農業生產更為高效與可持續。

## 三、技術限制與挑戰

儘管本次研究展示了 AI 技術在草莓病害檢測中的應用潛力，但仍然存在一些技術挑戰。首先，不同病害的特徵可能非常相似，尤其在早期階段，這對模型的精確識別能力提出了挑戰。其次，深度學習模型的表現仍然會受到訓練數據集大小的限制，未來需要進一步擴大數據集以提高模型的泛化能力。

此外，設備成本也是一個關鍵問題，特別是對於小型農戶而言，AOI 和 AMR 的實際應用可能需要較高的初始投資。最後，氣候條件的變化對影像數據的質量也可能產生影響，這將進一步影響系統的檢測準確性。因此，未來的工作應該關注於技術的成本效益分析，並持續優化模型的穩定性和適應能力。

## 伍、結論與建議

本研究探討了智慧農業技術在草莓病害檢測中的應用，特別是自動光學檢測(AOI)與自主移動機器人(AMR)技術的整合。結果顯示，透過這些先進技術，不僅顯著提高了草莓病害檢測的效率和準確度，還降低了人力成本，提升了整體經濟效益。同時，該系統的導入也促進了農業自動化和智能化的進程，有助於加快農業的現代化步伐。此外，在環境保護和可持續發展方面，精準的資源管理和減少農藥使用的措施，有效降低了農業對環境的負面影響，進一步提升了社會效益，促進了農村經濟發展。

為了進一步提升草莓病害識別系統的效能，建議推廣 AOI 與 AMR 技術於其他作物，以擴大智慧農業的應用範圍。同時，應加強深度學習與圖像識別技術的研發，提升模型的準確性和穩定性。在累積足夠的環境與病蟲害數據後，分析其關聯性以實現早期預警，進一步降低病害蔓延風險。此外，建議強化農民的技術培訓，以提升其對新技術的理解與應用能力。最後，呼籲政府提供政策與資金支持，促進智慧農業的可持續發展。

# 陸、參考文獻

## 一、中文部分


1. 詹婉渝，(2022)，基於深度學習影像辨識之稻米期別辨識系統，國立臺灣大學工程科學及海洋工程學系學位論文。
2. 陳耀茂，(2003)，田口統計解析法，臺北：五南文化。
3. 蘇朝墩，(2010)，品質工程，臺北：前程文化。


## 二、英文部分


1. Domingos, P. (2012). A few useful things to know about machine learning. *Communications of the ACM, 55*(10), 78-87. https://doi.org/10.1145/2347736.2347755
2. Fukushima, K. (1980). Neocognitron: A self-organizing neural network model for a mechanism of pattern recognition unaffected by shift in position. *Biological Cybernetics, 36*(4), 193-202.
3. Gonzalez, R. C., & Woods, R. E. (2018). *Digital image processing* (4th ed.). Pearson.
4. Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
5. Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. Advances in neural information processing systems, 27.
6. Hinton, G. E., & Salakhutdinov, R. R. (2006). Reducing the dimensionality of data with neural networks. *Science*, 313(5786), 504-507. https://doi.org/10.1126/science.1127647
7. Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735-1780. https://doi.org/10.1162/neco.1997.9.8.1735
8. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE conference on computer vision and pattern recognition* (pp. 770-778). https://doi.org/10.1109/CVPR.2016.90
9. Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. In *Advances in neural information processing systems* (Vol. 25, pp. 1097-1105).
10. LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature, 521*, 436-444. https://doi.org/10.1038/nature14539
11. LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE, 86*(11), 2278-2324. https://doi.org/10.1109/5.726791
12. Neubeck, A., & Van Gool, L. (2006). Efficient non-maximum suppression. In *Proceedings of the 18th international conference on pattern recognition* (Vol. 3, pp. 850-855).
13. Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. *Advances in neural information processing systems* (pp. 91-99).
14. Scherer, D., Müller, A., & Behnke, S. (2010). Evaluation of pooling operations in convolutional architectures for object recognition. In *Artificial Neural* Networks *and Machine Learning–ICANN 2010* (pp. 92-101). Springer.
15. Thrun, S., Burgard, W., & Fox, D. (2005). *Probabilistic robotics*. MIT Press.